STM32N6 기반 낙상 감지 모델 개발

Beamer 발표자료 초안

Graduate Project Team

Falling Model Development

March 19, 2026

프로젝트 목표

핵심 질문

오프라인 성능이 아니라 **STM32N6에 실제 배포 가능한 낙상 감지 모델**을 어떻게 만들 것인가?

- 입력: 자세 추정 기반 시계열 특징과 파생 기하 특징
- 목표: 미지 영상에서 높은 낙상 탐지율과 낮은 오경보율 확보
- 제약: `static shape`, `int8` 양자화, NPU 친화 연산 사용
- 산출물: 학습 파이프라인, 비교 기준 모델, 임베디드 배포 가능 구조

데이터셋 구성

- 전체 프레임 수: **4,093,620**
- 전체 비디오 수: **20,380**
- 전체 컬럼 수: **59**
- 입력 특징 수: **55**
- 양성 프레임: **314,740**
- 음성 프레임: **3,778,880**

특징 구성

- 키포인트 위치/신뢰도: 51개
- 파생 특징: 4개
- 라벨: 낙상 여부

문제 정의와 데이터 분할

중요 원칙

프레임 단위 랜덤 분할은 누수를 일으키므로 `video_id` **기준 그룹 분할**이 필수입니다.

- 권장 비율: Train 70%, Validation 15%, Test 15%
- 동일 비디오의 프레임은 항상 같은 split에만 포함
- 추가 hold-out 세트는 최종 배포 검증 전용으로 유지
- 평가 기준은 랜덤 프레임 정확도가 아니라 미지 비디오 일반화 성능

입력 시퀀스 설계

- 각 샘플을 **10초 클립**, 15 fps로 해석
- 실효 구간은 **5초에서 9초** 구간으로 고정
- 최종 입력 텐서 크기: 60×55
- 장점:
  - 정적 입력 형태 유지
  - 배포 파이프라인 단순화
  - fall onset 메타데이터 불완전 문제 완화

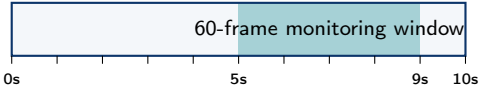

왜 TCN이 우선인가

TCN 장점

- `Conv1D`, `Add`, `BatchNorm`, `ReLU` 중심
- ONNX 변환 및 `int8` 양자화에 유리
- `static shape` 구조와 잘 맞음
- NPU 매핑 가능 연산 위주 설계 가능

GRU 한계

- 연구용 성능 기준선으로는 유효
- 상태 처리와 런타임 제약이 큼
- NPU 직접 매핑이 불리함
- export 이후 정확도 저하 위험 존재

추천 모델 아키텍처

Primary Model: Deployment-Oriented TCN

- 입력 형태: `(60, 55)`
- 깊이: 3–5 temporal convolution blocks
- dilation schedule: `1, 2, 4, 8`
- 채널 예시: `32 → 32 → 64 → 96`
- 활성화 함수: `ReLU`
- 출력 헤드: last-timestep logit 또는 pooled dense head

Secondary Model: GRU Baseline

- 1–2 layer GRU, hidden size 32–96
- 목적: TCN 대비 순수 정확도 기준선 확보

성능 목표와 평가 지표

주요 선택 지표

- Macro F1
- Fall-class Recall
- Fall-class Precision
- Video-level Detection Rate
- False Alarm Rate per Video
- Export 이후 Inference Latency

권장 목표치

- Accuracy $\geq$ 95%
- Recall $\geq$ 95%
- Precision $\geq$ 92%
- Macro F1 $\geq$ 0.94
- Unseen-video detection $\geq$ 95%

실험 및 배포 로드맵

1. **신뢰 가능한 baseline 구축**: grouped split, 고정 입력 구간, 재현 가능한 전처리 확립
2. **모델 비교**: TCN과 GRU를 동일 split에서 비교
3. **양자화 검증**: export, calibration, `int8` 정확도 저하 측정
4. **온디바이스 정합**: 임베디드 전처리와 학습 특징 생성 일치 확인
5. **최종 배포 평가**: 미사용 비디오와 실제 latency로 최종 선택

예상 리스크와 대응

- **라벨/이벤트 시점 불확실성**: 고정 모니터링 구간으로 우선 표준화
- **클래스 불균형**: recall과 false alarm을 함께 관리
- **양자화 성능 하락**: 연산자 단순화와 대표 데이터셋 기반 calibration 적용
- **임베디드 재현성**: 학습 특징은 반드시 디바이스에서도 계산 가능해야 함

결론

요약

이 프로젝트의 핵심은 **정확도가 높은 모델**이 아니라 **STM32N6에서 실제로 돌아가는 낙상 감지 시스템**을 만드는 것입니다.

- 현재 기준에서 **TCN**이 가장 현실적인 주력 아키텍처
- 입력은 **60** $\times$ **55** 고정 시퀀스로 표준화
- 평가는 **미지 비디오 기준 탐지율과 오경보율** 중심으로 수행
- 이후 단계는 **export, quantization, on-device 검증**까지 연결